

IDENTIFICATION DES 7 ETAPES KDD

Étape KDD	Action concrète (1-2 phrases)	Problème potentiel	Outil Python
1. Data Integration	Importer le fichier CSV des ventes et regrouper les données si elles proviennent de plusieurs sources afin d'obtenir un jeu de données unique.	Données dupliquées ou formats incompatibles entre les sources.	Pandas (<code>read_csv</code> , <code>concat</code> , <code>merge</code>)
2. Data Selection	Sélectionner uniquement les colonnes utiles à l'analyse, par exemple le produit, la quantité, le prix, la date et la région.	Conserver des variables inutiles ou supprimer des variables importantes.	Pandas
3. Data Cleaning	Corriger les valeurs manquantes, supprimer les doublons et traiter les valeurs aberrantes afin d'améliorer la qualité des données.	Valeurs manquantes, erreurs de saisie, doublons et données incohérentes.	Pandas (<code>dropna</code> , <code>fillna</code> , <code>drop_duplicates</code>)
4. Data Transformation	Convertir les types de données, normaliser les variables numériques et encoder les variables catégorielles si nécessaire.	Mauvais format des données ou variables difficiles à exploiter par les algorithmes.	Scikit-learn (<code>StandardScaler</code> , <code>LabelEncoder</code>)
5. Data Mining	Appliquer un algorithme de Data Mining pour extraire des connaissances, par exemple le	Choix d'un algorithme inadapté ou paramètres mal réglés.	Scikit-learn (<code>KMeans</code> , <code>DecisionTreeClassifier</code>)

	clustering ou la classification selon l'objectif.		
6. Pattern Evaluation	Évaluer la qualité des résultats obtenus à l'aide de mesures adaptées afin de vérifier leur pertinence.	Résultats peu fiables ou surapprentissage du modèle.	Scikit-learn (<code>accuracy_score</code> , <code>silhouette_score</code>)
7. Knowledge Presentation	Présenter les résultats sous forme de tableaux, graphiques et conclusions afin de faciliter leur interprétation.	Visualisations peu claires ou interprétation erronée des résultats.	Matplotlib ou Seaborn